

Mục lục

Lời nói đầu	3
1 Dữ liệu, Dữ liệu giả lập và Xử lý dữ liệu	4
1.1 Nguồn dữ liệu và Đặc tả KPI	4
1.2 Dữ liệu giả lập và Tính chất Non-IID	6
1.2.1 Đặc tính phân bố dữ liệu tại các Node	6
1.3 Quy trình Tiền xử lý dữ liệu (Preprocessing)	7
1.3.1 Chia dữ liệu	7
1.3.2 Làm sạch, Fill dữ liệu và Loại bỏ đặc trưng (Feature Selection)	7
1.3.3 Chuẩn hóa dữ liệu (Feature Scaling)	8
1.3.4 Tạo cửa sổ trượt (Sliding Window)	9
1.3.5 Chi tiết luồng xử lý (Data Pipeline Flow)	9
2 Cơ sở lý thuyết về Federated Learning và Chiến lược tối ưu hóa	10
2.1 Tổng quan về Federated Learning	10
2.2 Vấn đề dữ liệu Non-IID trong Viễn thông	11
2.3 Các thuật toán tổng hợp và Chiến lược tối ưu	11
2.3.1 Federated Averaging (FedAvg)	12
2.3.2 Federated Proximal (FedProx)	12
2.3.3 Federated Batch Normalization (FedBN)	12
3 Kiến trúc Hệ thống và Giao thức gRPC	14
3.1 Tổng quan Kiến trúc Hệ thống	14
3.2 Giao thức truyền thông gRPC	15
3.2.1 Tại sao chọn gRPC?	16
3.2.2 Định nghĩa Dịch vụ (Service Definition)	16
4 Môi trường thử nghiệm và kết quả	18

4.1	Các mô hình và Cấu trúc mạng	18
4.1.1	Tích hợp lớp Batch Normalization	18
4.2	Môi trường và Cấu hình thực nghiệm	19
4.2.1	Phần cứng và Phần mềm	19
4.2.2	Thiết lập Dữ liệu và Kích bản FL	20
4.3	Kết quả thực nghiệm và Đánh giá	21
4.3.1	So sánh chi phí truyền thông	21
4.3.2	So sánh quá trình hội tụ (Loss Comparison)	21
4.3.3	Tổng hợp kết quả định lượng (Quantitative Results)	24
4.3.4	So sánh evaluate trên tập giả lập và tập gốc	25
4.3.5	Tổng hợp thời gian chạy Fl	25

Lời nói đầu

Trong kỷ nguyên chuyển đổi số và sự bùng nổ của mạng viễn thông thế hệ mới (5G/6G), dữ liệu được sinh ra tại biên (Edge) đang gia tăng theo cấp số nhân. Các phương pháp Học máy tập trung (Centralized Machine Learning) truyền thống, mặc dù đạt hiệu quả cao, đang đối mặt với những thách thức nghiêm trọng về quyền riêng tư người dùng, chi phí băng thông truyền tải và các rào cản pháp lý trong việc lưu trữ dữ liệu tập trung. Trước bối cảnh đó, Học máy liên kết (Federated Learning - FL) đã nổi lên như một giải pháp đột phá, cho phép huấn luyện các mô hình AI trực tiếp trên thiết bị biên mà không cần thu thập dữ liệu thô về máy chủ.

Báo cáo này tập trung nghiên cứu và triển khai hệ thống Federated Learning ứng dụng trong việc phân tích và dự báo các chỉ số hiệu năng mạng (KPI). Đây là bài toán đặc thù với dữ liệu chuỗi thời gian (Time-series) có tính chất phân tán và không đồng nhất (Non-IID) cao giữa các khu vực mạng khác nhau.

Nội dung báo cáo trình bày toàn diện quy trình xây dựng một hệ thống FL thực nghiệm, bao gồm các giai đoạn then chốt:

- **Xử lý dữ liệu phân tán:** Kỹ thuật tiền xử lý, chuẩn hóa dữ liệu KPI viễn thông và mô phỏng các đặc tính Non-IID của môi trường thực tế.
- **Kiến trúc mô hình:** Lựa chọn và tối ưu hóa các mô hình học sâu (Deep Learning) như LSTM, Autoencoder phù hợp cho bài toán dự báo và phát hiện bất thường.
- **Triển khai hệ thống:** Xây dựng khung làm việc (Framework) dựa trên giao thức gRPC, cho phép giao tiếp hiệu quả giữa Server và nhiều Client giả lập.
- **Đánh giá và So sánh:** Thực nghiệm các thuật toán tối ưu hóa (FedAvg, FedProx, FedBN) và so sánh hiệu năng với mô hình huấn luyện tập trung (Centralized).

Chương 1

Dữ liệu, Dữ liệu giả lập và Xử lý dữ liệu

1.1 Nguồn dữ liệu và Đặc tả KPI

Dữ liệu sử dụng trong nghiên cứu là dữ liệu chuỗi thời gian (Time-series) mô phỏng hoạt động của mạng lõi 4G/LTE (EPC). Bộ dữ liệu bao gồm các chỉ số hiệu năng (Key Performance Indicators - KPI) được thu thập định kỳ, phản ánh trạng thái sức khỏe của các phần tử mạng như MME, SGW và PGW.

Mục tiêu của việc sử dụng bộ dữ liệu này trong Federated Learning là xây dựng mô hình phát hiện bất thường phân tán, có khả năng học từ các đặc tính lưu lượng khác nhau của từng khu vực mà không cần tập trung dữ liệu thô.

Bảng 1.1 dưới đây liệt kê chi tiết các KPI được giám sát:

Bảng 1.1: Danh sách các KPI và mô tả chi tiết

KPI Name	Unit	Mô tả
BEARER_MME_UTIL	%	Tỷ lệ sử dụng license bearer trên MME (BEARER_4G / License khai báo)
BEARER_4G	Count	Tổng số lượng Bearer đang hoạt động
CREATE_DEDICATED_BEARER_SR	%	Tỷ lệ thiết lập thành công dedicated bearer (thường dùng cho VoLTE)
CSFB_SR	%	Tỷ lệ thành công thủ tục CSFB chuyển thuê bao về 2G/3G để gọi thoại
DEDICATED_BEARER_MME	Count	Số lượng dedicated bearer đang hoạt động trên MME
Tiếp tục ở trang sau...		

Bảng 1.1 – tiếp theo từ trang trước

KPI Name	Unit	Mô tả
EASR	%	Tỷ lệ thiết lập E-RAB thành công (E-RAB Accessibility Success Rate)
INTRA_TAU_SR	%	Tỷ lệ cập nhật vùng (Tracking Area Update) nội bộ 4G thành công
PGW_BEARER_SR	%	Tỷ lệ thiết lập bearer thành công tại PGW/GGSN
PGW_BEARER_UTIL	%	Tỷ lệ sử dụng tài nguyên bearer trên PGW
S1_INTRA_HANDOVER_SR	%	Tỷ lệ chuyển giao (Handover) qua giao diện S1 nội bộ thành công
S1_PAGING_SR	%	Tỷ lệ Paging thành công qua giao diện S1
SAU_4G	Count	Số lượng thuê bao (Simultaneous Attached Users) trong hệ thống
SAU_UTIL_4G	%	Tỷ lệ sử dụng tài nguyên thuê bao (SAU_4G / License khai báo)
SERVICE_REQUEST_SR	%	Tỷ lệ thành công của thủ tục Service Request
SGW_BEARER_SR	%	Tỷ lệ thiết lập bearer thành công trên SGW
SG_LU_SR	%	Tỷ lệ cập nhật vị trí (Location Update) qua giao diện SGs thành công
SMS_PAGING_SR	%	Tỷ lệ Paging thành công cho dịch vụ SMS
THROUGHPUT_4G	Mbps	Lưu lượng dữ liệu 4G trung bình trong chu kỳ đo
THROUGHPUT_UTIL	%	Tỷ lệ sử dụng băng thông (THROUGHPUT_4G / License khai báo)
Tiếp tục ở trang sau...		

Bảng 1.1 – tiếp theo từ trang trước

KPI Name	Unit	Mô tả
NO_PGW_IMS_BEARER	Count	Số lượng IMS bearer trên PGW
NO_PGW_IMS_SUBS	Count	Số lượng thuê bao IMS trên PGW
NO_PGW_SUBS	Count	Tổng số lượng thuê bao trên PGW

1.2 Dữ liệu giả lập và Tính chất Non-IID

Trong bối cảnh thực tế, dữ liệu tại các trạm viễn thông (eNodeB hoặc khu vực Core Network) thường phân tán và không đồng nhất (Non-IID). Để mô phỏng kịch bản này, dữ liệu giả lập được xây dựng cho 3 Node (Client) với các đặc tính phân phối thống kê khác nhau về tải (Load) và hành vi thuê bao.

1.2.1 Đặc tính phân bố dữ liệu tại các Node

Hệ thống bao gồm 3 node đại diện cho 3 khu vực với đặc điểm khác nhau:

- **Node 1 (Heavy Load):**

- Đặc điểm: Số lượng thuê bao (SAU) cao, số lượng Bearer lớn và lưu lượng (Throughput) rất cao.
- Tính chất lỗi: Do hoạt động ở mức tải cao, Node này rất nhạy cảm với các suy hao hiệu năng. Khi xảy ra sự cố (ví dụ lỗi SPGW), các chỉ số giảm đột ngột và rõ rệt.


- **Node 2 (Medium Load):**

- Đặc điểm: Các chỉ số KPI ở mức trung bình, hoạt động ổn định, ít nhiễu (noise).
- Vai trò: Đóng vai trò là node chuẩn để kiểm chứng khả năng học của mô hình trong điều kiện lý tưởng.

- **Node 3 (Light Load):**

- Đặc điểm: Số lượng SAU và Bearer thấp, dẫn đến tỷ lệ sử dụng tài nguyên (%UTIL) thấp.
- Tính chất thống kê: Do mẫu số nhỏ, các chỉ số KPI tại Node 3 có phương sai

(Variance) lớn, dao động mạnh theo thời gian do tính di động (mobility) của thuê bao, gây khó khăn cho việc dự báo.



Hình 1.1: Data giả lập 3 node mạng

1.3 Quy trình Tiền xử lý dữ liệu (Preprocessing)

1.3.1 Chia dữ liệu

Để tránh hiện tượng data leakage, ta chia dữ liệu ở mỗi node thành 3 tập train, test, val theo tỉ lệ 70 15 15 trước khi thực hiện các bước xử lý dữ liệu tiếp theo (Đặc biệt là scaling).

1.3.2 Làm sạch, Fill dữ liệu và Loại bỏ đặc trưng (Feature Selection)

Để xử lý vấn đề các trường dữ liệu xuất hiện các giá trị null, quy trình tiền xử lý áp dụng chiến lược nội suy đa tầng:

- Nội suy tuyến tính theo thời gian
- Forward Fill & Backward Fill:

Dựa trên phân tích dữ liệu và đặc thù bài toán, các trường dữ liệu sau đây bị loại bỏ trước khi đưa vào mô hình. Việc này giúp giảm chiều dữ liệu và loại bỏ nhiễu. Dữ liệu gốc ban đầu có 24 trường, sau khi xóa sẽ còn 16 trường dữ liệu.

Chi tiết các trường bị loại bỏ và lý do:

- Nhóm định danh (Identifiers):
 - Các trường: node.
 - Lý do: Gây nhiễu, không giúp gì cho quá trình training.

- **Nhóm dẫn xuất dư thừa (Redundant/Derived Features):**

- **Các trường:** SAU_UTIL_4G, BEARER_MME_UTIL, PGW_BEARER_UTIL, THROUGHPUT_UTIL.
- **Lý do:** Đây là các trường tỷ lệ phần trăm được tính toán tuyến tính từ trường gốc (ví dụ: Util = Volume/Capacity). Giữ lại cả hai sẽ gây nhiễu.

- **Nhóm dữ liệu thưa/ít giá trị (Sparse/Low Variance):**

- **Các trường:** DEDICATED_BEARER_MME, NO_PGW_IMS_BEARER, NO_PGW_SUBS, NO_PGW_IMS_SUB
- **Lý do:** Phương sai thấp, không giúp mô hình học nhiều.

1.3.3 Chuẩn hóa dữ liệu (Feature Scaling)

Sau khi loại bỏ các trường trên, các trường còn lại được giữ lại và chia thành 3 nhóm để chuẩn hóa:

1. Nhóm Tỷ lệ thành công (Success Rates - %):

- **Các trường:** CREATE_DEDICATED_BEARER_SR, CSFB_SR, EASR, INTRA_TAU_SR, PGW_BEARER_SR, S1_INTRA_HANDOVER_SR, S1_PAGGING_SR, SERVICE_REQUEST_SR, SGW_BEARER_SR, SG_LU_SR, SMS_PAGGING_SR.
- **Phương pháp:** *MinMaxScaler* (về khoảng $[0, 1]$).
- **Đặc điểm:** Các trường này có miền giá trị cố định 0 – 100%.

$$x_{scaled} = \frac{x - x_{min}}{x_{max} - x_{min}}$$

2. Nhóm Lưu lượng mạng (Throughput):

- **Các trường:** THROUGHPUT_4G.
- **Phương pháp:** *StandardScaler* ($\mu = 0, \sigma = 1$).
- **Đặc điểm:** Lưu lượng mạng có tính chất phân phối chuẩn (Gaussian), phù hợp với Z-score normalization.

$$x_{scaled} = \frac{x - \mu}{\sigma}$$

3. Nhóm Số lượng/Dung lượng (Volume/Count):

- **Các trường:** SAU_4G (Số lượng thuê bao), BEARER_4G (Số lượng phiên kết nối), NO_PGW_IMS_SUBS .
- **Phương pháp:** *RobustScaler* (Dựa trên tứ phân vị IQR).
- **Đặc điểm:** Dữ liệu số lượng thuê bao thường chứa các điểm đột biến (spikes) do sự kiện hoặc hành vi người dùng. RobustScaler giúp giảm ảnh hưởng của các ngoại lai (outliers) này tốt hơn MinMaxScaler.

$$x_{scaled} = \frac{x - Q_1}{Q_3 - Q_1}$$

1.3.4 Tạo cửa sổ trượt (Sliding Window)

Dữ liệu chuỗi thời gian 2 chiều (T, F) được chuyển đổi thành dạng tensor 3 chiều ($N, windowlen, features$) và được training với eval ở $batchsize = 64$ để phù hợp với đầu vào của mạng LSTM:

- **Window Length** Kích thước cửa sổ trượt. Kết quả thử nghiệm được đo với $windowlen = 12$ tương ứng 60 phút (Ví dụ: 6, 12, 24, ... mẫu).
- **Overlap Rate:** Tỷ lệ chồng lấp giữa các cửa sổ liên tiếp để tăng cường số lượng mẫu huấn luyện. (Ví dụ: 0.5)

Ngoài thực hiện việc cắt dữ liệu này, đồng thời giữ lại thông tin thời gian ($start_window, end_window$) của mỗi cửa sổ và data raw để phục vụ cho việc đối soát kết quả sau này.

1.3.5 Chi tiết luồng xử lý (Data Pipeline Flow)

Để tích hợp các bước trên thành một quy trình hoàn chỉnh và giải quyết vấn đề rò rỉ dữ liệu (Data Leakage) và mất mát thông tin tại các điểm giao nhau giữa các tập dữ liệu, luồng xử lý được thực hiện theo trình tự sau:

1. **Phân chia dữ liệu thô thành 3 tập (Split Raw Data)**
2. **Học tham số chuẩn hóa (Fit Scaler):** Bộ chuẩn hóa (`DataScaler`) chỉ được thực hiện phương thức `.fit()` trên tập **Train Raw**.
3. **Áp dụng chuẩn hóa (Transform):** Sử dụng bộ Scaler đã fit ở bước trên để biến đổi (`.transform()`) cho cả 3 tập Train, Validation và Test.
4. **Xử lý tính liên tục (Continuity Handling):**
 - **Đối với tập Validation:** Hệ thống lấy một đoạn dữ liệu ở cuối tập Train (có độ dài bằng `window_len`) nối vào đầu tập Validation.
 - **Đối với tập Test:** Tương tự, lấy đoạn dữ liệu ở cuối tập Validation nối vào đầu tập Test.
5. **Tạo cửa sổ trượt (Sliding Window)**

Chương 2


Cơ sở lý thuyết về Federated Learning và Chiến lược tối ưu hóa

2.1 Tổng quan về Federated Learning

Học máy liên kết (Federated Learning - FL) là một phương pháp huấn luyện mô hình máy học phi tập trung. Thay vì thu thập dữ liệu thô từ các thiết bị biên (Client) về một máy chủ trung tâm (Server) để huấn luyện, FL cho phép huấn luyện mô hình ngay trên thiết bị biên và chỉ gửi các tham số mô hình (weights/gradients) đã được mã hóa về Server để tổng hợp.

Quy trình hoạt động cơ bản của FL bao gồm các bước lặp lại (Communication Rounds) như sau:

1. **Phân phối (Broadcast):** Server gửi mô hình toàn cục (Global Model w_t) xuống các Client được chọn.
2. **Huấn luyện cục bộ (Local Training):** Mỗi Client k sử dụng dữ liệu riêng $\mathcal{D}_k$ để huấn luyện mô hình, cập nhật trọng số thành w_{t+1}^k .
3. **Gửi cập nhật (Upload):** Client gửi trọng số mới (hoặc gradient) về Server.
4. **Tổng hợp (Aggregation):** Server tổng hợp các trọng số cục bộ để tạo ra mô hình toàn cục mới w_{t+1} .



Hình 2.1: Kiến trúc tổng quan của Federated Learning

2.2 Vấn đề dữ liệu Non-IID trong Viễn thông

Trong môi trường thực tế, đặc biệt là mạng viễn thông, dữ liệu tại các trạm phát sóng (eNodeB) hiếm khi tuân theo phân phối độc lập và đồng nhất (IID - Independent and Identically Distributed). Sự khác biệt này được gọi là **Non-IID** và là thách thức lớn nhất đối với sự hội tụ của mô hình FL.

Trong phạm vi đề án này, tính chất Non-IID thể hiện qua hai khía cạnh:

- **Sự lệch về số lượng**: Các node có sự khác nhau về số lượng mẫu
- **Sự lệch về phân phối đặc trưng**: Cùng một chỉ số (ví dụ: Throughput), nhưng phân phối xác suất tại Node tải nặng khác hoàn toàn so với Node tải nhẹ.

Hệ quả của Non-IID là hiện tượng *Weight Divergence* (Phân kỳ trọng số): Các client tối ưu hóa mô hình theo các hướng khác nhau, khiến mô hình toàn cục khó hội tụ hoặc dao động mạnh (Loss không ổn định).

2.3 Các thuật toán tổng hợp và Chiến lược tối ưu

Để giải quyết bài toán Non-IID, bên cạnh thuật toán cơ bản FedAvg, nghiên cứu này áp dụng hai chiến lược nâng cao là FedProx và FedBN.

2.3.1 Federated Averaging (FedAvg)

Đây là thuật toán nền tảng của FL, được đề xuất bởi McMahan et al. (2017). Server thực hiện tổng hợp bằng cách tính trung bình trọng số dựa trên số lượng mẫu dữ liệu của mỗi Client.

Công thức cập nhật:

$$w_{t+1} = \sum_{k=1}^K \frac{n_k}{n} w_{t+1}^k \quad (2.1)$$

Trong đó n_k là số mẫu của client k , và n là tổng số mẫu.

Hạn chế: FedAvg giả định dữ liệu là IID. Khi dữ liệu Non-IID, việc lấy trung bình trực tiếp có thể dẫn đến việc triệt tiêu các đặc trưng quan trọng riêng biệt của từng Client, làm giảm độ chính xác tổng thể.

2.3.2 Federated Proximal (FedProx)

FedProx (Li et al., 2020) được thiết kế để xử lý sự không đồng nhất của hệ thống và dữ liệu. Cơ chế cốt lõi của FedProx là thêm một số hạng *Proximal term* vào hàm mất mát (Loss function) cục bộ.

Hàm Loss mới tại Client k :

$$\min_w h_k(w; w_t) = F_k(w) + \frac{\mu}{2} ||w - w_t||^2 \quad (2.2)$$

Trong đó:

- $F_k(w)$: Hàm loss gốc (ví dụ MSE).
- w_t : Trọng số của Global Model ở vòng hiện tại.
- μ : Tham số kiểm soát (hyperparameter).

Tác động đến Non-IID: Số hạng $\frac{\mu}{2} ||w - w_t||^2$ đóng vai trò như một "sợi dây neo", ngăn không cho mô hình cục bộ đi quá xa so với mô hình toàn cục. Điều này giúp giảm thiểu sự phân kỳ trọng số giữa các Node có phân phối dữ liệu quá khác biệt (như giữa Node tải nặng và Node tải nhẹ), giúp quá trình huấn luyện ổn định hơn (giảm hiện tượng "gai" Loss).

2.3.3 Federated Batch Normalization (FedBN)

FedBN là phương pháp chuyên biệt để xử lý *Feature Shift* (Sự thay đổi phân phối đặc trưng).

Cơ chế hoạt động: Trong các mạng nơ-ron sâu (DNN/LSTM), lớp Batch Normalization (BN) chứa các tham số thống kê về dữ liệu (Mean μ và Variance σ^2).

- Trong FedAvg truyền thống: Server tổng hợp tất cả tham số, bao gồm cả các lớp BN. Điều này sai lầm vì μ, σ^2 của Node 1 khác hẳn Node 3. Việc cộng gộp chúng sẽ tạo ra một phân phối "lai tạp" không thực tế.
- Trong FedBN: Server **loại trừ** các tham số của lớp BN khỏi quá trình tổng hợp.

Quy trình cập nhật trọng số:

$$w_{t+1}^{Global} \leftarrow \text{Aggregate}(w_{local} \setminus \{BN_{params}\})$$


BN_{local}^k giữ nguyên tại Client k

Tác động đến Non-IID: Bằng cách giữ lại các lớp BN cục bộ, FedBN cho phép mỗi Client chuẩn hóa dữ liệu theo phân phối riêng của mình, trong khi vẫn chia sẻ kiến thức chung qua các lớp khác (LSTM, Linear). Điều này đặc biệt hiệu quả với dữ liệu KPI viễn thông, nơi các trạm có cấu hình tải khác nhau nhưng tuân theo quy luật vật lý mạng giống nhau.

Chương 3

Kiến trúc Hệ thống và Giao thức gRPC

3.1 Tổng quan Kiến trúc Hệ thống



Hình 3.1: Sơ đồ luồng hoạt động của hệ thống gRPC Federated Learning

Hệ thống Federated Learning được xây dựng theo mô hình Client-Server phi tập trung, bao gồm hai thành phần chính: một Máy chủ trung tâm (Central Server) và nhiều Máy trạm (Clients).

Quy trình hoạt động của hệ thống diễn ra theo các bước tuần tự sau (tương ứng với các khối trong sơ đồ):

1. **Khởi động hệ thống:** Server thực hiện mở cổng giao tiếp, Các Client gửi Join-Request tới server. Nếu đủ số lượng client ở config thì tiến hành khởi tạo và huấn luyện.
2. **Khởi tạo (Initialization):** Server khởi tạo mô hình toàn cục (Global Model) với các trọng số ngẫu nhiên hoặc được huấn luyện trước.
3. **Vòng lặp Huấn luyện (Training Rounds):** Hệ thống thực hiện R vòng lặp giao tiếp (Communication Rounds). Trong mỗi vòng:
 - (a) **Phân phối (Distribution):** Server gửi bộ tham số hiện tại của mô hình toàn cục (w_t) đến các Client được chọn thông qua giao thức gRPC.
 - (b) **Huấn luyện cục bộ (Local Training):** Mỗi Client nhận mô hình, sử dụng dữ liệu riêng của mình ($\mathcal{D}_k$) để thực hiện huấn luyện, cập nhật trọng số từ w_t thành w_{t+1}^k .
 - (c) **Gửi cập nhật thông qua LocalUpdateRequest (Upload Updates):** Sau khi huấn luyện xong, Client gửi bộ tham số mới (w_{t+1}^k) kèm theo thông tin về số lượng mẫu dữ liệu (n_k) và tính toán metric ngược trở lại Server. (Với gRPC sẽ gửi dữ liệu được đưa về binary)
 - (d) **Tổng hợp (Aggregation):** Server thu thập các bản cập nhật từ các Client. Khi nhận đủ số lượng yêu cầu, Server áp dụng thuật toán tổng hợp (như FedAvg, FedProx, FedBN) để tạo ra mô hình toàn cục mới (w_{t+1}).
4. **Kết thúc và Đánh giá:** Sau khi hoàn thành đủ số vòng lặp, hệ thống ngừng và mô hình toàn cục cuối cùng được sử dụng để đánh giá hiệu năng trên tập dữ liệu kiểm thử tập trung (**Tập test full của dữ liệu 3 node**)

3.2 Giao thức truyền thông gRPC

Để đảm bảo hiệu suất cao và khả năng mở rộng trong việc truyền tải các mô hình (như LSTM/Autoencoder) giữa Server và Client, hệ thống sử dụng giao thức **gRPC (Google**

Remote Procedure Call).

3.2.1 Tại sao chọn gRPC?

So với các giao thức truyền thống như REST API (sử dụng JSON/HTTP 1.1), gRPC mang lại nhiều ưu điểm vượt trội phù hợp cho Federated Learning:

- **Hiệu suất cao với Protocol Buffers (Protobuf):** gRPC mặc định sử dụng Protobuf để tuần tự hóa (serialize) dữ liệu. Protobuf là định dạng nhị phân, nhanh hơn gửi json
- **HTTP/2:** gRPC chạy trên nền tảng HTTP/2, hỗ trợ các tính năng như ghép kênh (multiplexing) - cho phép gửi nhiều yêu cầu song song trên cùng một kết nối TCP, và nén header, giúp tối ưu hóa độ trễ mạng.
- **Streaming hai chiều (Bi-directional Streaming):** Hỗ trợ kết nối liên tục.

3.2.2 Định nghĩa Dịch vụ (Service Definition)

Giao diện giao tiếp giữa Server và Client được định nghĩa rõ ràng trong file `.proto` (`fedfl.proto`). Proto quy định các phương thức có thể gọi và cấu trúc dữ liệu được trao đổi.

Listing 3.1: Định nghĩa Protobuf cho dịch vụ Federated Learning

```
package fedfl;

service FederationService {
    rpc SendWeights (WeightRequest) returns (WeightResponse) {}
    rpc GetGlobalModel (Empty) returns (ModelResponse) {}
}

message JoinRequest {
    int32 client_id = 1;
    int32 num_samples = 2;
}

message LocalUpdateRequest {
    int32 client_id = 1;
    bytes serialized_weights = 2;
    int32 num_samples = 3;
    float train_loss = 4;
```



```
float train_mae = 5;
float train_mse = 6;
}

message WeightsResponse {
    bytes serialized_weights = 1;
    int32 round_id = 2;
    bool is_final = 3;
    bool wait_join = 4;
}
```

Sử dụng protobuf đảm bảo giao tiếp hiệu quả, giảm chi phí truyền thông đáng kể

Chương 4

Môi trường thử nghiệm và kết quả

Chương này trình bày chi tiết về thiết lập môi trường thực nghiệm, các cấu hình cụ thể cho quá trình huấn luyện Federated Learning và Centralized Learning. Tổng hợp và phân tích kết quả đạt được thông qua các biểu đồ trực quan và bảng số liệu so sánh hiệu năng giữa các phương pháp.

4.1 Các mô hình và Cấu trúc mạng

Dựa trên cơ sở lý thuyết và mã nguồn thực tế (file `models.py`), các mô hình học sâu được sử dụng trong thực nghiệm bao gồm:

- **LSTMModel:** Mạng LSTM
- **Các kiến trúc Autoencoder:** AELSTM, AECNN, VAE, VAELSTM

4.1.1 Tích hợp lớp Batch Normalization

Cải tiến trong kiến trúc các mô hình là việc tích hợp các lớp **Batch Normalization (BN1d)** sau các tầng xử lý chính (LSTM output, Conv1D output, hoặc sau các lớp Linear trong VAE/AE) và trước hàm kích hoạt.

Việc thêm lớp BN mang lại hai lợi ích cốt lõi:

1. **Ổn định quá trình huấn luyện:**
2. **Hỗ trợ thuật toán FedBN:**

Bảng 4.1: Tóm tắt kiến trúc và số lượng tham số các mô hình (Dựa trên models.py)

Tên Mô hình	Kiến trúc tóm tắt (Main Layers)	Input Shape	Tổng tham số
LSTMModel	LSTM(64, layers=2) $\rightarrow$ BN $\rightarrow$ FC(Output)	(Batch, Seq, Feat)	54,209
AELSTM	Enc: LSTM(64) $\rightarrow$ BN $\rightarrow$ FC(32) $\rightarrow$ BN Dec: FC(64) $\rightarrow$ BN $\rightarrow$ LSTM(64) $\rightarrow$ FC	(Batch, Seq, Feat)	59,503
AECNN	Enc: Conv1D(32) $\rightarrow$ BN $\rightarrow$ Conv1D(16) $\rightarrow$ BN Dec: ConvT1D(32) $\rightarrow$ BN $\rightarrow$ ConvT1D(In)	(Batch, Seq, Feat)	6,207
VAE	Enc: FC(64) $\rightarrow$ BN $\rightarrow$ $\mu(16), \sigma(16)$ Dec: FC(64) $\rightarrow$ BN $\rightarrow$ FC(Output)	(Batch, Seq, Feat)	5,423
VAELSTM	Enc: LSTM(64) $\rightarrow$ BN $\rightarrow$ $\mu(16), \sigma(16)$ Dec: FC(64) $\rightarrow$ BN $\rightarrow$ LSTM(64) $\rightarrow$ FC	(Batch, Seq, Feat)	58,415

*Ghi chú: Input Shape dạng (Batch size, Seq, Feat). Trong thực nghiệm sử dụng (64, 6, 15).

4.2 Môi trường và Cấu hình thực nghiệm

4.2.1 Phần cứng và Phần mềm

Quá trình huấn luyện và đánh giá được thực hiện trên hệ thống máy chủ với cấu hình phần cứng và môi trường phần mềm như sau:

- **CPU:** Intel64 Family 6 Model 158 Stepping 13(4 cores,8 logical processors)

- **RAM:** Total Physical Memory: 8,044 MB .

4.2.2 Thiết lập Dữ liệu và Kích bản FL

Dữ liệu KPI viễn thông được chia tách để mô phỏng môi trường Non-IID thực tế với 3 Clients (Nodes) có đặc tính phân phối khác nhau:

- **Client 1:** Node tải cao (Heavy Load).
- **Client 2:** Node tải trung bình (Medium Load).
- **Client 3:** Node tải thấp (Light Load).

Mỗi Client sử dụng 70% dữ liệu cục bộ để huấn luyện và 30% để Validation và Test. Server sử dụng một tập dữ liệu kiểm thử tập trung (Global Test Set) được gộp từ 15% dữ liệu của tất cả các node để đánh giá mô hình toàn cục.

Các tham số cấu hình chung cho quá trình huấn luyện Federated Learning được thống kê trong Bảng 4.2.

Bảng 4.2: Cấu hình tham số huấn luyện Federated Learning

Tham số	Giá trị	Mô tả
Communication Rounds	200	Tổng số vòng lặp giao tiếp Server-Client.
Window len	12	Tương ứng 12 mẫu dữ liệu 1 window.
Overlap rate	0.5	Tỉ lệ trùng lặp giữa các window
Total Clients (K)	3	Tổng số lượng Client tham gia.
Fraction Fit (C)	100	Tỷ lệ Client tham gia huấn luyện mỗi vòng.
Local Epochs (E)	1	Số epoch huấn luyện cục bộ tại mỗi Client.
Batch Size (B)	64	Kích thước batch cho huấn luyện cục bộ.
Optimizer	Adam	Thuật toán tối ưu hóa với LR mặc định $1e - 3$.
FedProx μ	0.01	Tham số điều hòa cho thuật toán FedProx.
Learning rate	0.001	Tốc độ học
Loss Function	MSE/MAE	MSE, MAE

4.3 Kết quả thực nghiệm và Đánh giá

Phần này trình bày kết quả so sánh hiệu năng giữa phương pháp tập trung (Centralized) và các chiến lược Federated Learning (FedAvg, FedProx, FedBN) trên các mô hình đã đề cập.

4.3.1 So sánh chi phí truyền thông


Dưới đây sẽ là kết quả chi phí truyền thông chạy FL của các mô hình được đề cập.

Bảng 4.3: Tổng hợp chi phí truyền thông toàn bộ quá trình Federated Learning (200 Rounds, 3 Clients)


Mô hình	Chi phí truyền thông (MB)
AE-CNN	37.19
VAE	130.71
LSTM	258.96
VAE-LSTM	278.31
AE-LSTM	284.54

4.3.2 So sánh quá trình hội tụ (Loss Comparison)


Các hình dưới đây thể hiện biểu đồ hàm mất mát (Global Loss) trên tập kiểm thử tập trung qua các vòng huấn luyện.




Hình 4.1: So sánh Global Loss của mô hình **LSTMModel** giữa Centralized và các chiến lược FL.




Hình 4.2: So sánh Global Loss của mô hình **AELSTM** giữa Centralized và các chiến lược FL.



Hình 4.3: So sánh Global Loss của mô hình $\mathbf{VAE}_{LSTM}(Standard)$ và $Centralized$ và $ccchincFL$.



Hình 4.4: So sánh Global Loss của mô hình $\mathbf{VAE}$ giữa $Centralized$ và các chiến lược FL.



Hình 4.5: So sánh Global Loss của mô hình $\mathbf{AE}_{CNN}$ giữa $\mathbf{Centralized}$ và $\mathbf{cchinh}$ $\mathbf{FL}$.

4.3.3 Tổng hợp kết quả định lượng (Quantitative Results)

Bảng 4.4 tổng hợp độ đo lỗi MAE và MSE cuối cùng trên tập Global Test.

Bảng 4.4: Bảng so sánh Metrics (MAE/MSE) trên tập Global Test giữa các mô hình và chiến lược huấn luyện (Số liệu thực nghiệm cập nhật)

Model	Centralized		FedAvg		FedProx		FedBN	
	MAE	MSE	MAE	MSE	MAE	MSE	MAE	MSE
AECNN	0.20804	0.08432	0.24087	0.11079	0.23558	0.10618	0.23871	0.10951
VAE	0.18909	0.06150	0.22967	0.09749	0.23131	0.09721	0.22747	0.09589
VAELSTM	0.18707	0.06118	0.26084	0.14428	0.25920	0.14387	0.25997	0.14456
AELSTM	0.17167	0.04926	0.25493	0.13767	0.25630	0.13836	0.25377	0.13509
LSTMMModel	0.25837	0.15519	0.27472	0.16499	0.27175	0.16232	0.27166	0.16262

Phân tích kết quả thực nghiệm: Dựa trên số liệu tại Bảng 4.4, ta có các nhận xét chi tiết sau:

- **Hiệu năng của Centralized Learning:** Mô hình huấn luyện tập trung (Centralized) đạt kết quả tốt nhất (MSE/MAE thấp nhất) trên các kiến trúc Autoencoder (AECNN, VAE, VAELSTM, AELSTM).

- **So sánh các chiến lược Federated Learning:**

- **FedAvg:** Thường cho kết quả kém nhất trong ba phương pháp. Do cơ chế tính trung bình trọng số trực tiếp (bao gồm cả các tham số Batch Normalization) từ các Client có phân phối dữ liệu khác nhau (Non-IID).
- **FedBN:** Phương pháp này đạt kết quả tốt nhất trên các mô hình có cấu trúc Autoencoder hoặc CNN sâu (như **AECNN** và **VAE**). -> Với dữ liệu KPI viển thông phân tán, việc cho phép mỗi client tự học và giữ lại các tham số Mean/Variance cục bộ là hiệu quả để xử lý vấn đề lệch phân phối đặc trưng.
- **FedProx:** Thể hiện sự ổn định cao và đạt hiệu quả tốt nhất trên các mô hình thuần chuỗi thời gian như **AELSTM** (MSE **0.106**) và **LSTMModel**.

4.3.4 So sánh evaluate trên tập giả lập và tập gốc

Bảng 4.5: So sánh hiệu năng mô hình AECNN trên Dữ liệu Giả lập (Simulated) và Dữ liệu Thực tế (Real)

Phương pháp	Test trên Sim Data		Test trên Real Data		Độ lệch (Gap)	
	MAE	MSE	MAE	MSE	Δ MAE	Δ MSE
Centralized	0.2080	0.0843	0.2936	0.1695	+41.1%	+101.1%
FedAvg	0.2409	0.1108	0.2678	0.1096	+11.2%	-1.1%
FedProx	0.2356	0.1062	0.2744	0.1094	+16.5%	+3.0%
FedBN	0.2387	0.1095	0.2841	0.1158	+19.0%	+5.7%

**Ghi chú: Số liệu lấy từ mô hình AECNN. Sim Data là tập kiểm thử tổng hợp từ 3 node giả lập. Real Data là tập dữ liệu gốc thực tế. Cột Độ lệch thể hiện sự thay đổi khi chuyển từ môi trường Sim sang Real.*

4.3.5 Tổng hợp thời gian chạy FL

Kết quả thực nghiệm cho thấy thời gian huấn luyện toàn trình của Federated Learning (FL) có sự chênh lệch nhất định giữa các phương pháp. Cụ thể, phương pháp FedAvg và FedBN có tổng thời gian thực thi ngang nhau và nhanh nhất. FedProx có thời gian chạy FL lâu nhất. Nguyên nhân chính xuất phát từ chi phí tính toán proximal term nhằm xử

lý vấn đề non-IID.

Bảng 4.6: Tổng hợp thời gian chạy Federated Learning của các mô hình

Mô hình	Phương pháp FL	Thời gian chạy (s)
AECNN	FedAvg	175.2
	FedProx	187.3
	FedBN	155.9
VAE	FedAvg	120.6
	FedProx	121.5
	FedBN	122.7
VAE-LSTM	FedAvg	140.9
	FedProx	156.0
	FedBN	158.6
AELSTM	FedAvg	129.3
	FedProx	150.6
	FedBN	126.9
LSTM	FedAvg	201.6
	FedProx	272.3
	FedBN	264.0